

Detecção sequencial de quebras estruturais sob avaliação transversal: formulação, estatísticas e agregação

Resumo. Estudamos o problema de detectar, em tempo real e sem revisão retrospectiva, a ocorrência de uma quebra estrutural num processo estocástico do qual se observa previamente uma realização livre de quebra. O problema difere da detecção clássica de pontos de mudança em dois aspectos que determinam toda a solução: a decisão é sequencial e irrevogável, e a avaliação é *transversal* — o desempenho é medido comparando, num mesmo instante, os escores atribuídos a um conjunto de processos independentes. Demonstramos que esse funcional de avaliação é invariante a transformações monótonas comuns a todos os processos, e derivamos as consequências: componentes do escore que dependam apenas do tempo são exatamente neutros, ao passo que normalizações idiossincráticas por processo não o são. Sobre essa base, construímos uma redução ao regime nulo por filtragem autorregressiva congelada e apresentamos a matemática de nove famílias de estatísticas de detecção, organizadas pelo tipo de alternativa que cada uma detecta e pelo funcional (supremo ou integral) que aplicam ao caminho amostral. Discutimos a agregação por modelo aditivo em log-odds, incluindo um resultado de fusão exata que permite promediar réplicas de treino sem custo de inferência. Por fim, tratamos da metodologia de comparação: decompomos a variância do estimador de desempenho em componente de amostragem e componente de treino, mostramos que ignorar a segunda invalida o teste usual, e formalizamos o viés de seleção que surge quando uma configuração é escolhida sob a mesma realização do gerador aleatório usada para avaliá-la.

1. Introdução

A detecção de quebras estruturais tem duas tradições. A **retrospectiva** pergunta, dada uma série completa, onde estão os pontos de mudança; admite formulações por minimização de custo penalizado e é resolvida por programação dinâmica ou segmentação. A **sequencial**, iniciada por Page e Shiryaev, pergunta quando parar e declarar mudança, com critérios de atraso médio de detecção sujeito a uma taxa de alarme falso.

O problema aqui pertence à segunda tradição, mas com uma diferença que se revela decisiva: não se pede uma regra de parada, e sim, a cada instante, um **escore de evidência**; e a qualidade desse escore não é medida por atraso ou taxa de falso alarme, mas por sua capacidade de **ordenar** um conjunto de processos independentes observados simultaneamente. Essa mudança de funcional de avaliação não é cosmética: ela torna irrelevantes propriedades usualmente centrais — calibração absoluta, por exemplo — e torna centrais outras que a teoria sequencial clássica não enfatiza, como a comparabilidade de escala entre processos com dinâmicas nulas distintas.

Organizamos o texto assim. A §2 formaliza o problema e demonstra a propriedade de invariância do funcional de avaliação, da qual decorrem as decisões estruturais subsequentes. A §3 apresenta a redução ao regime nulo. A §4, o núcleo técnico, desenvolve a matemática das famílias de estatísticas. A §5 trata da calibração idiossincrática. A §6, da agregação por aprendizado supervisionado e de um resultado de fusão exata. A §7 desenvolve a metodologia de comparação. A §8 reporta resultados empíricos, a §9 os discute, e a §10 conclui.

2. Formulação

2.1 Modelo probabilístico

Considere N processos indexados por i . Para cada i observa-se uma realização histórica $\{x_s^{(i)}\}_{s=1}^{n_i}$, garantidamente gerada por um regime estacionário $P_0^{(i)}$, seguida de um fluxo $\{x_t^{(i)}\}_{t \geq 1}$ no qual pode existir um instante de quebra $\tau_i \in \mathbb{N} \cup \{\infty\}$ tal que

$$x_t^{(i)} \sim \begin{cases} P_0^{(i)}, & t < \tau_i \\ P_1^{(i)}, & t \geq \tau_i \end{cases}$$

com $P_1^{(i)} \neq P_0^{(i)}$ desconhecida. Note que os regimes nulos $P_0^{(i)}$ **diferem entre processos** — alguns exibem heterocedasticidade condicional, outros dependência linear persistente, outros caudas pesadas. Esta heterogeneidade é essencial: ela implica que uma mesma estatística assume, sob a hipótese nula, distribuições distintas conforme o processo, e que comparar seus valores brutos entre processos é comparar quantidades não comensuráveis.

Seja $\mathcal{F}_t^{(i)}$ a filtração gerada pelo histórico e por $\mathbf{x}_{1:t}^{(i)}$. Um **detector** é uma família de funções mensuráveis $S_t : \mathcal{F}_t^{(i)} \rightarrow \mathbb{R}$. A restrição de causalidade é estrita: S_t não pode depender de $\mathbf{x}_s^{(i)}$ para $s > t$, nem do comprimento total do fluxo, nem de qualquer estatística agregada sobre os outros processos no mesmo instante.

2.2 O funcional de avaliação

Defina o rótulo $y_t^{(i)} = \mathbf{1}\{\tau_i \leq t\}$. Para cada instante t , seja $\mathcal{P}_t = \{i : y_t^{(i)} = 1\}$ e $\mathcal{N}_t = \{i : y_t^{(i)} = 0\}$, com cardinalidades n_t^+ e n_t^- . A área sob a curva ROC da seção transversal no instante t é

$$A_t = \frac{1}{n_t^+ n_t^-} \sum_{i \in \mathcal{P}_t} \sum_{j \in \mathcal{N}_t} \left[\mathbf{1}\{S_t^{(i)} > S_t^{(j)}\} + \frac{1}{2} \mathbf{1}\{S_t^{(i)} = S_t^{(j)}\} \right],$$

e o funcional de avaliação é a média ponderada

$$\mathcal{A} = \frac{\sum_t w_t A_t}{\sum_t w_t}, \quad w_t = n_t^+ n_t^-.$$

A ponderação por w_t é a que faz de $\mathcal{A}$ um estimador da probabilidade de concordância agregada sobre todos os pares discordantes disponíveis em todos os instantes.

2.3 Invariância e suas duas consequências

Proposição 1 (invariância a transformações comuns). Seja $\varphi_t : \mathbb{R} \rightarrow \mathbb{R}$ estritamente crescente, e considere o detector transformado $\tilde{S}_t^{(i)} = \varphi_t(S_t^{(i)})$, com a *mesma* φ_t para todo i . Então $\tilde{A}_t = A_t$ para todo t , e portanto $\tilde{\mathcal{A}} = \mathcal{A}$.

Demonstração. A_t depende de $\{S_t^{(i)}\}$ apenas através dos indicadores $\mathbf{1}\{S_t^{(i)} > S_t^{(j)}\}$ e $\mathbf{1}\{S_t^{(i)} = S_t^{(j)}\}$. Monotonicidade estrita de φ_t preserva ambas as relações. $\square$

Duas consequências, de sinais opostos, governam o desenho de todo o sistema.

Corolário 1.1 (neutralidade do componente comum). Qualquer parcela do score que dependa apenas de t — em particular a taxa-base $\pi(t) = \Pr(\tau \leq t)$ marginalizada sobre processos — é neutra para $\mathcal{A}$. Formalmente, se $S_t^{(i)} = g(\mathcal{F}_t^{(i)}) + h(t)$, então $\mathcal{A}$ não depende de h .

Isto elimina de saída a calibração absoluta como objetivo: o score não precisa ser uma probabilidade, e esforço dedicado a torná-lo uma não pode, por construção, melhorar o desempenho medido.

Corolário 1.2 (não-neutralidade do componente idiossincrático). Se $\tilde{S}_t^{(i)} = \varphi^{(i)}(S_t^{(i)})$ com $\varphi^{(i)}$ dependente do processo, então em geral $\tilde{A}_t \neq A_t$.

Este é o resultado que motiva a §5: como os regimes nulos diferem entre processos, uma padronização que use a distribuição nula *de cada processo* altera a ordenação e pode, em princípio, melhorá-la. A distinção entre os Corolários 1.1 e 1.2 é sutil e sua confusão é uma fonte concreta de erro: uma transformação que *parece* idiossincrática mas é, na prática, quase constante entre processos — porque a quantidade que a define tem variabilidade desprezível entre eles — recai no Corolário 1.1 e é inócua.

Observação (variância induzida pela estimação). Suponha $\varphi^{(i)}(s) = (s - \hat{\mu}_i)/\hat{\sigma}_i$ com $\hat{\mu}_i$ estimado a partir de m observações do regime nulo do processo i . O erro $\hat{\mu}_i - \mu_i$ é **independente entre processos**. No instante t , esse erro entra na comparação transversal como ruído aditivo puro, de variância $\text{Var}(\hat{\mu})$, não compartilhado. Portanto uma padronização idiossincrática só melhora a ordenação se a heterogeneidade que ela remove exceder o ruído de estimação que ela injeta — um balanço que depende de m e que deve ser verificado, não assumido.

3. Redução ao regime nulo

3.1 Filtragem autorregressiva congelada

Ajusta-se sobre o histórico um modelo autorregressivo de ordem p ,

$$x_s = c + \sum_{k=1}^p \phi_k x_{s-k} + \varepsilon_s,$$

por mínimos quadrados, aceitando-o apenas se a redução relativa da variância residual exceder um limiar. Opcionalmente inclui-se um termo sazonal num atraso ℓ selecionado pela autocorrelação amostral. A inovação padronizada é

$$e_s = \frac{\varepsilon_s}{\sigma_\varepsilon},$$

truncada a um intervalo simétrico para limitar a influência de observações extremas isoladas.

O ponto essencial não é o ajuste, e sim o **congelamento**: os coeficientes estimados no histórico são aplicados sem reestimação a todo o fluxo online. Isto tem duas consequências.

Primeiro, sob H_0 a sequência $\{e_t\}$ é aproximadamente ruído branco de variância unitária, e qualquer estatística com distribuição nula conhecida sob ruído branco torna-se utilizável.

Segundo, e mais importante, e_t é o erro de predição um-passo do filtro do histórico. Logo, se o regime muda de modo que a estrutura de dependência de segunda ordem se altere, o filtro deixa de branquear e a perda de brancura de $\{e_t\}$ é ela própria a evidência de quebra — sem que nada precise ser reestimado. Reestimar o filtro online seria contraproducente: ele absorveria a quebra que se quer detectar. Esta é a razão pela qual o objeto que caracteriza o regime nulo é construído uma única vez e mantido imutável.

3.2 Normalização de volatilidade e o problema da absorção

Para processos com dependência na volatilidade, a inovação padronizada por uma escala fixa não é homocedástica, o que distorce estatísticas que pressupõem variância constante. A correção natural é uma normalização adaptativa,

$$v_t = (1 - \lambda)v_{t-1} + \lambda e_t^2, \quad \tilde{e}_t = \frac{e_t}{\sqrt{v_t}},$$

que produz uma sequência aproximadamente homocedástica.

Essa correção, porém, tem um custo que precisa ser explicitado. Suponha que em τ a variância salte de 1 para $\rho^2 > 1$. Então $\mathbb{E}[v_t] \rightarrow \rho^2$ com constante de tempo $1/\lambda$, e portanto

$$\mathbb{E}[\tilde{e}_t^2] \rightarrow 1 \quad \text{para } t - \tau \gg 1/\lambda.$$

A normalização **absorve** a quebra de variância: após algumas dezenas de passos, a sequência normalizada é indistinguível do regime nulo. Uma estatística de variância calculada sobre $\tilde{e}_t$ é, portanto, cega precisamente ao alternativo mais frequente.

Daí a regra de roteamento adotada: estatísticas cujo alvo é **escala ou cauda** consomem a inovação de escala congelada; estatísticas cujo alvo é **localização, dependência ou forma** consomem a versão normalizada. Trata-se de um trade-off explícito entre robustez a

heterocedasticidade nula e sensibilidade a heterocedasticidade induzida pela quebra, resolvido separadamente por família.

4. Famílias de estatísticas de detecção

Organizamos as famílias por dois eixos: a **alternativa** que cada uma privilegia (localização, escala, dependência, forma de cauda, distribuição inteira) e o **funcional** que aplicam ao caminho amostral da evidência acumulada — de tipo supremo ou de tipo integral, distinção desenvolvida em §4.8.

4.1 Razão de verossimilhança sequencial: a estatística de Page

Para detectar um deslocamento de magnitude δ na média de inovações $\mathcal{N}(0, 1)$, o incremento da log-verossimilhança sob a alternativa contra a nula é

$$\log \frac{f_{\delta}(e_t)}{f_0(e_t)} = \delta e_t - \frac{\delta^2}{2}.$$

A estatística de soma cumulativa refletida,

$$G_t = \max\left(0, G_{t-1} + \delta e_t - \frac{\delta^2}{2}\right), \quad G_0 = 0,$$

é o teste sequencial de razão de verossimilhança generalizado com reinício. Sob H_0 o incremento tem média $-\delta^2/2 < 0$, o que faz de G_t uma cadeia positiva recorrente com distribuição estacionária; sob a alternativa a média torna-se $+\delta^2/2 > 0$ e G_t cresce linearmente. É ótimo no sentido de Lorden para δ conhecido.

A construção se estende a outras alternativas substituindo a razão de verossimilhança apropriada: para uma mudança de escala de fator ρ ,

$$\log \frac{f_{\rho}(e_t)}{f_1(e_t)} = -\log \rho + \frac{e_t^2}{2} \left(1 - \frac{1}{\rho^2}\right),$$

e analogamente para proporção de sinal (Bernoulli), taxa de excedência de um quantil de referência, e autocovariância defasada, esta última usando o produto $e_t e_{t-1}$ como escore.

Duas quantidades são extraídas de cada detector: o valor corrente e a **idade desde o último reinício**, isto é, $t - \max\{s \leq t : G_s = 0\}$. Sob H_0 os reinícios são frequentes e a idade permanece pequena; sob a

alternativa o detector deixa de reiniciar e a idade cresce linearmente, fornecendo um estimador implícito de τ .

4.2 Posterior sobre o comprimento de execução

Uma alternativa bayesiana mantém a distribuição a posteriori do **comprimento de execução** $\mathbf{r}_t$, definido como o número de observações desde a última mudança. Com prior de risco constante $\mathbf{H}$ (equivalente a uma geométrica sobre o intervalo entre mudanças), a recursão é

$$p(\mathbf{r}_t, \mathbf{x}_{1:t}) = \sum_{\mathbf{r}_{t-1}} p(\mathbf{r}_t | \mathbf{r}_{t-1}) p(\mathbf{x}_t | \mathbf{r}_{t-1}, \mathbf{x}^{(r)}) p(\mathbf{r}_{t-1}, \mathbf{x}_{1:t-1}),$$

com $p(\mathbf{r}_t = \mathbf{r}_{t-1} + 1 | \mathbf{r}_{t-1}) = 1 - \mathbf{H}$ e $p(\mathbf{r}_t = \mathbf{0} | \mathbf{r}_{t-1}) = \mathbf{H}$. Adotando prior conjugado normal–gama–inversa para média e variância do regime, a preditiva $p(\mathbf{x}_t | \mathbf{r}_{t-1}, \mathbf{x}^{(r)})$ é uma t de Student, o que confere robustez a caudas pesadas.

Extraem-se: a razão de verossimilhança logarítmica entre "houve mudança recente" e "não houve", o modo da posterior de $\mathbf{r}_t$, e a idade implícita $t - \mathbf{r}_t^{\text{MAP}}$. O custo por passo é linear no truncamento do suporte de $\mathbf{r}_t$.

4.3 Martingales conformais

Esta família dispensa qualquer suposição paramétrica. Dado o conjunto de referência do histórico, define-se para cada observação online um p -valor conformal por posto médio,

$$p_t = \frac{\#\{s : \alpha_s > \alpha_t\} + \frac{1}{2} \#\{s : \alpha_s = \alpha_t\} + \frac{1}{2}}{n + 1},$$

onde α é uma medida de não-conformidade (valor com sinal, ou módulo, conforme a alternativa visada). Sob permutabilidade — que vale sob $\mathbf{H}_0$ — os p_t são aproximadamente i.i.d. uniformes.

Um **martingale de apostas** é então

$$M_T = \prod_{t=1}^T \epsilon p_t^{\epsilon-1}, \quad \epsilon \in (0, 1),$$

e, como $\int_0^1 \epsilon u^{\epsilon-1} du = 1$, tem-se $\mathbb{E}[M_T | \mathcal{F}_{T-1}] = M_{T-1}$ sob $\mathbf{H}_0$: M é martingale não-negativa de valor inicial 1. Pela desigualdade de Ville,

$$\Pr \left(\sup_T M_T \geq 1/\alpha \right) \leq \alpha,$$

o que fornece controle de erro tipo I **uniforme no tempo**, sem correção para múltiplas comparações — propriedade que nenhuma das famílias anteriores possui. Uma mistura sobre ϵ evita a escolha de um único parâmetro de aposta. Sob a alternativa, os p_t concentram-se perto de zero e $\log M_T$ cresce linearmente.

4.4 Embeddings de kernel

Para detectar mudanças na distribuição inteira, e não apenas em momentos escolhidos, usa-se a discrepância média máxima. Para um kernel característico k com espaço de Hilbert associado $\mathcal{H}$,

$$\text{MMD}^2(P, Q) = \|\mu_P - \mu_Q\|_{\mathcal{H}}^2, \quad \mu_P = \mathbb{E}_{X \sim P}[k(X, \cdot)],$$

que se anula se e somente se $P = Q$. O cálculo direto é quadrático no número de amostras, inviável sequencialmente. Pelo teorema de Bochner, um kernel invariante a translação e positivo definido é a transformada de Fourier de uma medida de probabilidade, o que autoriza a aproximação por características aleatórias:

$$k(x, y) \approx z(x)^\top z(y), \quad z(x) = \sqrt{\frac{2}{D}} [\cos(\omega_1 x + b_1), \dots, \cos(\omega_D x + b_D)]^\top,$$

com ω_j amostradas da medida espectral e b_j uniformes. A média empírica de z pode então ser mantida recursivamente, e a discrepância contra a referência do histórico torna-se uma norma euclidiana em dimensão D , com custo constante por passo.

Duas variantes são úteis: a marginal, sobre e_t , e a conjunta, sobre o par (e_t, e_{t-1}) , esta última sensível a mudanças na estrutura de dependência que preservam a marginal. Uma terceira construção compara duas médias exponenciais de velocidades distintas, dispensando referência fixa e tornando-se um detector de mudança *relativa* ao passado recente.

4.5 Decomposição multiescala

O nível de energia sozinho não distingue três alternativas qualitativamente distintas: um patamar persistente de variância, uma explosão transitória de volatilidade, e uma deriva lenta. A separação requer decompor a energia em bandas de frequência disjuntas.

A transformada de Haar fornece a decomposição mais barata compatível com causalidade. Em cada escala j , pares consecutivos (a, b) produzem

$$d^{(j)} = \frac{a - b}{\sqrt{2}} \quad (\text{detalhe}), \quad s^{(j)} = \frac{a + b}{\sqrt{2}} \quad (\text{aproximação}),$$

com a aproximação alimentando a escala $j+1$. A transformada é ortonormal, de modo que sob ruído branco de variância unitária $\mathbb{E}[(d^{(j)})^2] = 1$ em toda escala — as energias já nascem comparáveis entre processos, sem normalização adicional. Mantendo uma média exponencial de $(d^{(j)})^2$ por escala e formando contrastes entre escalas finas e grossas, obtém-se um descritor do *formato* da curva energia-versus-escala, que é o que discrimina as três alternativas acima.

4.6 Momentos de ordem e forma de cauda

Momentos convencionais de ordem elevada são inúteis quando a distribuição tem caudas pesadas, pois podem não existir. Os **L-momentos**, definidos como combinações lineares de esperanças de estatísticas de ordem,

$$\lambda_1 = \mathbb{E}[X], \quad \lambda_2 = \frac{1}{2} \mathbb{E}[X_{2:2} - X_{1:2}], \quad \lambda_3 = \frac{1}{3} \mathbb{E}[X_{3:3} - 2X_{2:3} + X_{1:3}],$$

existem sempre que o primeiro momento existe. As razões adimensionais $\tau_3 = \lambda_3/\lambda_2$ (L-assimetria) e $\tau_4 = \lambda_4/\lambda_2$ (L-curtose) são estimadores de forma robustos, calculados em janelas móveis.

4.7 Variação bipotência e separação de saltos

Para distinguir um aumento de volatilidade contínua de uma sequência de saltos, usa-se o contraste entre a variância realizada e a variação bipotência,

$$RV_n = \sum_{i=1}^n e_i^2, \quad BV_n = \frac{\pi}{2} \sum_{i=2}^n |e_i| |e_{i-1}|.$$

Sob um processo de difusão sem saltos, ambas convergem para a variação quadrática integrada e a razão $RV/BV \rightarrow 1$; na presença de saltos, RV incorpora os quadrados dos saltos enquanto BV permanece robusto a eles, e a razão excede 1. A construção se completa com semivariâncias — as somas restritas a incrementos de cada sinal — cuja assimetria detecta mudanças na direcionalidade, e com a correlação entre sinal e magnitude subsequente, que capta efeito de alavancagem.

4.8 Funcionais de tipo supremo e de tipo integral

Todas as famílias anteriores extraem do caminho amostral da evidência acumulada um funcional do tipo **supremo**: a soma cumulativa guarda seu máximo refletido, a posterior bayesiana seu modo, o martingale é dominado por seu pico. A teoria clássica de testes de estabilidade

distingue essa classe de uma segunda, de tipo **integral**, com perfil de potência diferente.

Considere a ponte construída a partir das somas parciais centradas de uma janela de n observações $u_1, \dots, u_n$:

$$B_i = \sum_{j \leq i} (u_j - \bar{u}) = P_i - \frac{i}{n} P_n, \quad P_i = \sum_{j \leq i} u_j.$$

A estatística de tipo integral é

$$\eta_n = \frac{1}{n^2 \hat{\sigma}^2} \sum_{i=1}^n B_i^2,$$

que sob a hipótese de estabilidade converge em distribuição para $\int_0^1 \mathbb{B}^\circ(r)^2 dr$, onde $\mathbb{B}^\circ$ é a ponte browniana padrão. Como $\mathbb{E}[\mathbb{B}^\circ(r)^2] = r(1-r)$, segue

$$\mathbb{E} \left[\int_0^1 \mathbb{B}^\circ(r)^2 dr \right] = \int_0^1 r(1-r) dr = \frac{1}{6},$$

um valor **universal**: independente da distribuição de u , de sua variância e de suas caudas. A divisão por $\hat{\sigma}^2$ torna a estatística auto-normalizada, e a construção da ponte a torna invariante a deslocamentos — de modo que a comparabilidade entre processos é obtida por construção, sem estimar nenhuma constante idiossincrática, evitando o ruído descrito na Observação da §2.3.

A distinção de potência é a seguinte. Um funcional de supremo é sensível a um desvio grande e localizado; um de integral, ao desvio acumulado ao longo da janela. Segue que o segundo domina quando a alternativa é difusa — deriva gradual, múltiplas quebras pequenas — e, notavelmente, quando a quebra ocorre **próximo ao fim da janela**: nesse regime o supremo ainda não acumulou evidência, mas a ponte inteira já se deslocou.

A mesma ponte pode ser aplicada a diferentes **representações** do fluxo, cada uma sensível a um tipo de alternativa: a inovação (localização), seu quadrado (escala), e sua transformação integral de probabilidade contra a distribuição do histórico (a distribuição inteira, de forma livre de distribuição e robusta a caudas).

Uma observação de completude: a representação por **diferenças primeiras** é degenerada nesta construção. Se $u_j = e_j - e_{j-1}$, a soma parcial telescopa, $P_i = e_i - e_0$, a ponte torna-se função dos valores

brutos e η_n colapsa numa variância de janela — quantidade já contemplada por outras famílias. A verificação é algébrica e dispensa experimento.

4.9 Entropias espectral e ordinal

Duas construções merecem menção por serem **invariantes a escala por definição**, e portanto estruturalmente incapazes de duplicar a informação das famílias de variância.

Entropia espectral. Estimando a densidade espectral de potência em K bandas por transformada de Fourier de tempo curto com janela exponencial, e formando as proporções $\hat{p}_k = \hat{P}_k / \sum_j \hat{P}_j$, define-se o centroide $\sum_k \hat{p}_k \omega_k$ e a entropia $-\sum_k \hat{p}_k \log \hat{p}_k$. Ambas são razões, logo invariantes a multiplicação do processo por constante. Sob ruído branco o espectro é chato: entropia máxima e centroide central. Persistência positiva desloca massa para baixas frequências; alternância, para altas — e o centroide, ao contrário de somas de quadrados de autocorrelações, **tem sinal**, distinguindo as duas direções.

Um cuidado é essencial. O periodograma num único instante é assintoticamente exponencial: seu desvio padrão iguala sua média, *qualquer que seja o comprimento da série*. As proporções $\hat{p}$ tornam-se então aproximadamente **Dirichlet(1, ..., 1)**, para a qual

$$\mathbb{E} \left[-\sum_{k=1}^K p_k \log p_k \right] = \psi(K+1) - \psi(2),$$

com ψ a função digama. Para $K=6$ isto vale $\approx 1,45$, ou **0,81** após normalização por $\log K$ — bem abaixo do máximo teórico, e com dispersão entre realizações comparável ao efeito que se deseja medir. A correção necessária é promediar periodogramas (estimador de Welch), o que reduz a variância sem viés apreciável. Trata-se de um caso geral: **uma estatística construída como razão de estimativas ruidosas não converge com o comprimento da série**; apenas promediação explícita a estabiliza.

Entropia de permutação. Para cada bloco de m observações consecutivas, registra-se apenas o padrão de ordenação — um dos $m!$ símbolos. A entropia normalizada da distribuição empírica desses símbolos numa janela,

$$H_m = -\frac{1}{\log m!} \sum_{\pi} \hat{p}(\pi) \log \hat{p}(\pi),$$

é máxima sob independência e diminui sob qualquer dependência serial, sem escolher atraso nem supor linearidade. Sua propriedade distintiva é a invariância a **qualquer transformação monótona ponto-a-ponto**: escala, cauda e normalização são invisíveis. Uma variante mede **irreversibilidade temporal**, $\frac{1}{2} \sum_{\pi} |\hat{p}(\pi) - \hat{p}(\pi^R)|$ com π^R o padrão do bloco lido em ordem inversa; sob qualquer processo reversível no tempo — o que inclui todo processo linear gaussiano — essa soma tem esperança nula, de modo que ela isola não-linearidade com direção temporal.

5. Calibração contra o regime nulo idiossincrático

Pelo Corolário 1.2, padronizar cada estatística pela sua distribuição nula *no processo em questão* pode alterar — e potencialmente melhorar — a ordenação transversal. Para uma estatística de janela $\mathcal{S}$, estimam-se $\hat{\mu}_i$ e $\hat{\sigma}_i$ aplicando o mesmo estimador ao histórico do processo i , que é nulo por construção, e define-se

$$S^{\text{cal}} = \frac{S - \hat{\mu}_i}{\hat{\sigma}_i}.$$

Duas ressalvas teóricas delimitam a aplicabilidade.

(i) Estatísticas recursivas exigem tratamento distinto. Para uma estatística de janela, o histórico fornece muitas observações aproximadamente independentes do valor nulo. Para uma estatística recursiva com reinício — como as somas cumulativas de §4.1 — a distribuição nula depende de t durante um regime transitório antes de atingir a estacionariedade, e uma passagem contínua pelo histórico estima a distribuição estacionária, não a transitória. A estimação correta requer réplicas com reinício, o que reduz drasticamente o número efetivo de amostras independentes.

(ii) O balanço ruído-versus-heterogeneidade. Pela Observação da §2.3, a padronização injeta ruído transversal de variância $\text{Var}(\hat{\mu}_i) + S^2 \text{Var}(\hat{\sigma}_i)/\sigma_i^2$, independente entre processos. Ela só compensa se a heterogeneidade removida for maior. Em particular, se a estatística crua já for aproximadamente comensurável entre processos — como ocorre, por construção, para as energias de Haar de §4.5 e para os funcionais integrais de §4.8 —, a calibração adiciona ruído sem remover

viés, e o efeito líquido é negativo. Este é o cenário em que uma coluna calibrada e sua versão crua exibem correlação transversal próxima de um: o resíduo não carrega ordenação nova, apenas erro de estimação.

6. Agregação

6.1 Remoção do componente comum

O rótulo y_t tem taxa-base $\pi(t)$ fortemente crescente. Pelo Corolário 1.1, esse componente é neutro para o funcional de avaliação; contudo, ele domina qualquer perda pontual usada como substituto de treino — a log-perda binária, por exemplo, é minimizada em primeira ordem por acertar $\pi(t)$, e não por ordenar corretamente dentro do instante.

A solução é decompor o preditor como

$$S_t^{(i)} = \sigma\big(g(\mathbf{z}_t^{(i)}) + \text{logit } \hat{\pi}(t)\big),$$

fixando o segundo termo como deslocamento conhecido e ajustando apenas g . O modelo aprende então o **resíduo transversal** — exatamente a quantidade que o funcional mede — em vez de gastar capacidade numa componente que o funcional ignora.

Na emissão do score, o deslocamento pode ser omitido sem prejuízo, pelo Corolário 1.1; a escolha entre incluí-lo ou não é indiferente para a avaliação e decidível por outros critérios, como o comportamento fora do suporte de treino.

6.2 Modelo aditivo e validação por agrupamento

O agregador g é um modelo aditivo em log-odds ajustado por *boosting* de gradiente sobre árvores,

$$g(\mathbf{z}) = \sum_{b=1}^B f_b(\mathbf{z}), \quad f_b \text{ árvore de regressão},$$

escolha motivada por três propriedades: invariância a transformações monótonas de cada coordenada — o que dispensa normalização das features e é coerente com a Proposição 1 —, tratamento nativo de valores ausentes, que é essencial porque estatísticas de janela longa são genuinamente indefinidas nos primeiros instantes, e capacidade de representar interações, necessária porque a interpretação de um detector

depende do regime nulo do processo (§2.1), o que é uma interação entre features dinâmicas e descritores estáticos.

A validação cruzada deve agrupar por processo: todas as linhas de um mesmo processo pertencem à mesma partição. Sem isso, o modelo memoriza processos individuais e a estimativa fora da amostra é otimista de forma severa, já que linhas do mesmo processo em instantes vizinhos são fortemente dependentes.

6.3 Agregação sobre réplicas de treino e fusão exata

O procedimento de ajuste é aleatório: a amostragem de colunas e de linhas em cada iteração de *boosting* faz de g uma variável aleatória mesmo com dados fixos. Seja $g^{(1)}, \dots, g^{(K)}$ um conjunto de réplicas independentes. O preditor médio tem variância reduzida por fator $1/K$ na componente idiossincrática de treino, e portanto desempenho esperado superior ao de uma réplica única — o argumento clássico de agregação bootstrap.

O obstáculo é o custo: a inferência é sequencial, uma observação por vez, e avaliar K modelos multiplica por K um custo dominado por sobrecarga fixa de chamada, não por travessia de árvores.

Há, contudo, um resultado exato que elimina o obstáculo. Como cada $g^{(m)}$ é uma **soma** de árvores, tem-se

$$\frac{1}{K} \sum_{m=1}^K g^{(m)}(\mathbf{z}) = \frac{1}{K} \sum_{m=1}^K \sum_b f_b^{(m)}(\mathbf{z}) = \sum_{m,b} \frac{1}{K} f_b^{(m)}(\mathbf{z}),$$

isto é, a média das K réplicas é *ela própria* um modelo aditivo, obtido concatenando todas as árvores e escalando cada valor de folha por $1/K$. A agregação passa a custar uma única avaliação.

Uma sutileza: a identidade vale no espaço de log-odds. A média das probabilidades, $\frac{1}{K} \sum_m \sigma(g^{(m)})$, difere de $\sigma(\frac{1}{K} \sum_m g^{(m)})$ por desigualdade de Jensen, e as duas podem, em princípio, ordenar processos de modo distinto. A escolha entre elas é uma questão empírica; a diferença é de segunda ordem quando os $g^{(m)}$ são próximos.

7. Metodologia de comparação

Esta seção trata de um problema de inferência estatística sobre o próprio procedimento experimental, independente do domínio de aplicação.

7.1 Decomposição da variância do estimador

Seja $\hat{\mathcal{A}}(\theta, \xi)$ a estimativa do funcional de avaliação para uma configuração θ (conjunto de estatísticas, hiperparâmetros), onde ξ denota a realização do gerador aleatório do procedimento de ajuste. A quantidade de interesse ao comparar θ_1 e θ_0 é

$$\Delta = \mathbb{E}_{\xi} [\hat{\mathcal{A}}(\theta_1, \xi)] - \mathbb{E}_{\xi} [\hat{\mathcal{A}}(\theta_0, \xi)].$$

O estimador usual toma uma realização de cada lado, $\hat{\Delta} = \hat{\mathcal{A}}(\theta_1, \xi_1) - \hat{\mathcal{A}}(\theta_0, \xi_0)$, e constrói um intervalo de confiança por **bootstrap pareado sobre processos**: reamostram-se índices i com reposição e recomputa-se $\hat{\mathcal{A}}$ para ambos os lados sobre a *mesma* reamostragem.

Esse procedimento estima corretamente a componente de variância devida à amostragem de processos, e o pareamento cancela a maior parte da covariância entre os lados. Mas ele **condiciona em ξ_1 e ξ_0** : trata os preditores como funções fixas. A variância total do estimador é

$$\text{Var}(\hat{\Delta}) = \underbrace{\text{Var}_{\text{amostra}}(\hat{\Delta})}_{\text{capturada pelo bootstrap}} + \underbrace{\text{Var}_{\xi} [\hat{\mathcal{A}}(\theta_1, \xi)] + \text{Var}_{\xi} [\hat{\mathcal{A}}(\theta_0, \xi)]}_{\text{invisível ao bootstrap}},$$

onde o segundo termo não é cancelado pelo pareamento porque ξ_1 e ξ_0 são realizações independentes — e necessariamente distintas, já que alterar a configuração altera o próprio espaço sobre o qual o gerador atua.

Se Var_{ξ} for da ordem dos efeitos procurados, o intervalo de confiança do bootstrap é severamente anticonservador, e a taxa de erro tipo I do procedimento de decisão é muito maior que a nominal. A correção é direta: estimar $\mathbb{E}_{\xi}$ por média sobre K réplicas de cada lado, reduzindo o segundo termo por fator $1/K$, e reportar as duas famílias como distribuições.

7.2 Viés de seleção sobre a realização do gerador

Um segundo efeito, mais insidioso, surge quando a configuração é escolhida por comparações conduzidas sob uma **realização fixa ξ^*** . Seja

$\theta^* = \arg \max_{\theta \in \Theta} \hat{\mathcal{A}}(\theta, \xi^*)$ o resultado de uma sequência de decisões desse tipo. Então

$$\mathbb{E} \left[\hat{\mathcal{A}}(\theta^*, \xi^*) \right] > \mathbb{E}_{\xi} \left[\hat{\mathcal{A}}(\theta^*, \xi) \right],$$

isto é, o valor observado sob a realização de seleção é otimisticamente enviesado — a maldição do vencedor aplicada não a uma escolha isolada, mas acumulada ao longo de todas as decisões do processo de desenvolvimento.

O efeito tem uma assinatura empírica verificável e específica: a realização ξ^* deve ser excepcionalmente favorável para θ^* e **neutra para configurações vizinhas**, já que a vantagem decorre de uma interação entre a configuração selecionada e aquela realização particular, e não de uma qualidade intrínseca. Observar essa assinatura distingue o viés de seleção de uma flutuação aleatória de cauda.

A consequência prática é grave: se o baseline de comparação é θ^* avaliado em ξ^* , toda comparação subsequente é enviesada **contra** qualquer alternativa, e a taxa de falsos negativos do procedimento de decisão é elevada por um mecanismo sistemático, não aleatório.

7.3 Protocolo corrigido

Decorre do exposto: (i) estimar cada lado por média sobre K réplicas, com o mesmo K ; (ii) excluir das comparações a realização usada historicamente para seleção; (iii) declarar antes da medição o subconjunto do domínio em que se espera o efeito, sob pena de a multiplicidade implícita inflar o erro tipo I; (iv) precedendo qualquer ciclo caro, aplicar um teste de necessidade — uma estatística candidata cuja correlação com uma já existente, *dentro do instante*, seja próxima de um não pode, pela Proposição 1, alterar a ordenação, e portanto não pode mover o funcional, independentemente de sua motivação teórica.

O ponto (iv) merece ênfase: trata-se de condição **necessária e não suficiente**. Uma direção nova no espaço de estatísticas pode ser ortogonal ao banco existente e simultaneamente ortogonal ao sinal.

8. Resultados empíricos

Os experimentos usam 10^4 processos com histórico e fluxo online, avaliados fora da amostra por validação cruzada agrupada por processo.

Todos os contrastes seguem o protocolo da §7.3, com **K** réplicas por lado e exclusão da realização de seleção.

8.1 Estrutura do desempenho ao longo do tempo

O funcional decompõe-se por regime temporal com pesos **w_t** muito desiguais:

regime	peso relativo em $\mathcal{A}$	desempenho
$t \leq 50$	8,1%	0,536
$50 < t \leq 150$	26,6%	0,580
$150 < t \leq 400$	48,7%	0,624
$t > 400$	16,5%	0,653

A concentração do peso no regime intermediário implica que melhorias restritas ao regime inicial — onde o desempenho é mais fraco e a tentação de intervir é maior — são, por construção, quase indetectáveis no agregado.

8.2 Magnitude da componente de variância de treino

Sete réplicas independentes de uma mesma configuração, com dados, estatísticas e partições idênticos, diferindo apenas na realização do gerador do procedimento de ajuste:

0,6006 0,6015 0,6016 0,6020 0,6022 0,6030 0,6032

com média **0,6020** e desvio-padrão **0,0009**. O erro-padrão da diferença entre duas configurações avaliadas com **uma réplica cada** é portanto **$\approx 0,0013$** ; incluindo a realização usada historicamente para seleção, o desvio sobe para **0,0041** e o erro-padrão para **0,0058**.

Três contrastes anteriormente julgados negativos, reavaliados contra esse referencial:

contraste	$\hat{\Delta}$	em unidades de erro-padrão	conclusão correta
calibração de estatísticas recursivas	−0,0069	1,2	inconclusivo
detector bayesiano com poda	−0,0042	0,7	inconclusivo
brancura multi-atraso	−0,0024	0,4	inconclusivo

8.3 Assinatura do viés de seleção

A realização historicamente usada produz, para a configuração selecionada sob ela, desempenho nove desvios-padrão acima da média

das demais realizações. O contraste com configurações vizinhas confirma a assinatura prevista em §7.2:

configuração	sob a realização de seleção	média das demais	excesso
a selecionada	0,6100	0,6019	+0,0081
com família espectral	0,6035	0,6039	−0,0004
com família ordinal	0,6030	0,6031	−0,0001
com família integral	0,6048	0,6080	−0,0032

A vantagem é específica da configuração selecionada e não transfere para nenhuma modificação, o que é incompatível com flutuação aleatória e consistente com interação seleção-realização.

8.4 Contribuição das famílias

Contra o referencial reavaliado de **0,6020**, com *K* réplicas por lado:

família acrescentada	$\hat{\Delta}$	conclusão
funcionais de tipo integral (§4.8)	+0,0036	adotada
detector bayesiano de run-length com remoção de estatísticas de baixa contribuição	+0,0056	positiva, não combinável
— apenas a remoção	+0,0027	componente
— apenas o detector	+0,0029	componente
entropia espectral (§4.9)	+0,0021	abaixo do critério
entropia de permutação (§4.9)	+0,0012	abaixo do critério
brancura multi-atraso	+0,0004	abaixo do critério
agregação sobre 4 réplicas de treino (§6.3)	+0,0040	adotada

Para a família adotada, o intervalo de confiança pareado exclui zero a favor no agregado (**+0,0042**, IC 95% [**+0,0022**, **+0,0063**]) e no regime declarado a priori. O maior efeito relativo ocorre no regime inicial, coerente com a predição teórica de §4.8: é ali que a quebra está tipicamente próxima ao fim da janela de observação.

8.5 Não-aditividade

A união das duas famílias com efeito positivo isolado mede **0,6054**, **abaixo de cada uma separadamente**. Os detectores capturam informação parcialmente sobreposta; a união acrescenta dimensão sem acrescentar poder de ordenação.

8.6 Saturação da agregação sobre réplicas

<i>K</i>	desempenho	ganho marginal
1	0,6020	—
2	0,6047	+0,0026
4	0,6060	+0,0005
7	0,6068	+0,0002

O comportamento é o esperado para redução de variância por promediação: o ganho decresce como a componente idiossincrática remanescente, e satura quando o erro residual passa a ser comum às réplicas.

9. Discussão

Sobre o funcional de avaliação. A Proposição 1 e seus corolários não são observações auxiliares: elas determinam quais problemas vale a pena resolver. Calibração absoluta, monotonicidade temporal do escore e suavização são todos exercícios neutros. Em contrapartida, a comparabilidade *entre processos* torna-se o problema central, e é notável que ele admita duas soluções qualitativamente distintas — padronização estimada (§5), que injeta ruído idiossincrático, e auto-normalização por construção (§4.8), que não. A evidência empírica favorece a segunda.

Sobre o valor de uma hipótese de falha. Três famílias introduzidas nesta rodada eram igualmente inéditas em relação ao banco existente, verificadas pelo teste de necessidade da §7.3. Apenas uma produziu efeito. A que produziu não era a mais sofisticada, mas a única acompanhada de uma hipótese sobre *em que regime* o conjunto existente falha — a saber, que funcionais de supremo perdem potência quando a quebra está próxima ao fim da janela. As outras duas eram justificadas por ortogonalidade, que é condição necessária e vazia isoladamente.

Sobre a remoção de estatísticas. A observação de que remover doze estatísticas de baixa contribuição *aumenta* o desempenho merece atenção teórica. Num modelo aditivo com amostragem de colunas, cada dimensão sem sinal reduz a probabilidade de que dimensões informativas sejam consideradas numa dada divisão, um efeito de diluição. A magnitude observada sugere que o conjunto está além do ponto ótimo dessa troca.

Sobre a metodologia. O resultado de §7.1–7.2 transcende esta aplicação. Sempre que um procedimento de ajuste é aleatório e comparações são feitas com uma realização por lado, o intervalo de confiança usual é anticonservador de forma não quantificada. Sempre que um referencial é o produto de uma sequência de seleções sob uma realização fixa, comparações contra ele são enviesadas de forma sistemática. Ambos os efeitos são baratos de diagnosticar — basta reajustar o referencial contra si mesmo — e, quando presentes, invalidam retroativamente decisões tomadas com o instrumento defeituoso.

10. Conclusão

Formalizamos a detecção sequencial de quebras estruturais sob um funcional de avaliação transversal, demonstrando que a invariância desse funcional a transformações monótonas comuns elimina uma classe inteira de objetivos e eleva outra à centralidade. Sobre uma redução ao regime nulo por filtragem congelada, organizamos nove famílias de estatísticas segundo a alternativa visada e o funcional aplicado ao caminho amostral, destacando a distinção entre funcionais de supremo e de integral como eixo pouco explorado e empiricamente produtivo. Apresentamos um resultado de fusão exata que torna gratuita, em custo de inferência, a agregação sobre réplicas de ajuste.

A contribuição de maior alcance, contudo, é metodológica: a demonstração de que o procedimento de comparação usualmente adotado ignora a componente de variância devida ao próprio ajuste e é enviesado por seleção acumulada sobre uma realização fixa do gerador aleatório. Ambos os efeitos foram quantificados e revelaram-se da ordem de grandeza dos efeitos que se pretendia medir, o que invalidou três decisões anteriores e obrigou à revisão do protocolo experimental.

As direções abertas seguem dessa revisão. A remoção sistemática de estatísticas de baixa contribuição tem justificativa teórica e evidência preliminar favorável. A não-aditividade documentada em §8.5 sugere que o conjunto de detectores está próximo de saturação informacional, e que ganhos adicionais exigirão não novas estatísticas sobre as mesmas representações, mas hipóteses explícitas sobre regimes de falha ainda não cobertos — dos quais o mais persistente é a quebra puramente de dependência sem alteração de escala.